

Lasso 回归优化实验报告

基于 Subgradient、ISTA、FISTA 与 ADMM 的比较研究

最优化课程小组

2026 年 6 月 5 日

摘要

本文围绕 Lasso 回归中的优化求解问题展开，比较了 Subgradient Descent、ISTA、FISTA 和 ADMM 四种算法在稀疏恢复任务中的表现。实验部分以合成数据为主线，系统考察了主实验设置、正则化参数 λ 、ADMM 参数 ρ 、噪声强度、重复实验稳定性、问题规模扩展、正则化路径与相变分析；同时在 `diabetes`、`wine_red` 和 `Communities and Crime` 三个真实数据集上验证模型的预测性能与稀疏性表现。为增强结论可信度，本文还引入 `sklearn.linear_model.Lasso` 作为参考对照。结果表明：ISTA、FISTA 与 ADMM 都能有效求解 Lasso，其中 ADMM 在保持解质量接近的同时通常具有更少的迭代次数；噪声和正则化强度会显著影响稀疏恢复效果；在复杂真实数据上，更强的正则化才能更明显地体现特征选择作用。

1 课题背景与研究目标

本课题围绕 Lasso 回归中的优化问题展开，重点比较以下四种算法在稀疏回归任务上的表现：

- Subgradient Descent
- ISTA
- FISTA
- ADMM

Lasso 模型写作

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

其中，第一项刻画拟合误差，第二项通过 L_1 正则诱导稀疏性。

本项目的研究目标包括：

1. 在合成稀疏数据上比较四种算法的恢复误差、稀疏性和收敛速度；

2. 分析正则化参数 λ 与 ADMM 参数 ρ 的影响；
3. 分析噪声强度对稀疏恢复的影响；
4. 在真实数据集上验证算法在实际回归任务中的预测表现；
5. 通过正则化路径和相变分析补足 Lasso 主题下更完整的实验层次。

2 算法说明

2.1 Subgradient Descent

该方法直接对非光滑目标函数做次梯度下降，作为 baseline。它实现简单，但步长敏感、收敛慢，在本实验中主要用于说明直接处理非光滑项的局限性。

2.2 ISTA

ISTA 是经典近端梯度法。每一步先对光滑项做梯度下降，再对 L_1 项施加软阈值算子，因此能够更自然地处理 Lasso 问题。

2.3 FISTA

FISTA 是 ISTA 的加速版本，通过 Nesterov 动量项提升收敛速度。理论和实践上都应优于或不差于 ISTA。

2.4 ADMM

ADMM 通过变量分裂把 Lasso 问题拆分成二次子问题与软阈值子问题，适合处理“光滑项 + 非光滑项”的组合优化问题。本课题中，ADMM 是最核心的方法之一。

3 数据集设置

3.1 合成数据

合成数据用于主实验，因为真实稀疏解 x^* 已知，可以直接评估：

- 恢复误差 $\|\hat{x} - x^*\|_2$
- 非零元素个数
- 支撑集恢复是否成功

合成数据构造方式如下：

1. 生成高斯随机矩阵 A ;
2. 按列归一化, 减弱特征尺度不一致带来的影响;
3. 生成稀疏真实信号 x^* , 仅保留少数非零元素;
4. 加入高斯噪声, 构造观测 $b = Ax^* + \varepsilon$ 。

3.2 真实数据

目前使用了三个真实回归数据集:

- **diabetes**: 来自 `sklearn`, 规模较小, 适合作为真实数据补充实验;
- **winequality-red.csv**: 来自 UCI Wine Quality 数据集, 使用红酒子集作为第二个真实数据验证场景。
- **Communities and Crime**: 来自 UCI, 存在缺失值, 特征更多, 适合作为复杂真实高维回归场景的补充实验。

原本尝试接入 **California Housing**, 但运行中遇到远程下载的 HTTP 403 问题, 因此最终采用了本地可控的 **wine_red** 与 **Communities and Crime** 数据。

需要特别说明的是: 合成数据与真实数据并不是做完全相同的实验, 而是有明确分工:

- **合成数据**: 负责机制分析。因为知道真实稀疏解, 所以可以做恢复误差、支撑集恢复、相变分析、噪声实验和规模扩展实验。
- **真实数据**: 负责应用验证。因为真实数据中不知道真实系数, 所以重点考察预测误差、稀疏性和收敛效率。

4 实验实现中的修正与改进

这一部分很重要, 因为本项目并不是一次性得到完美结果, 而是经历了“初版结果不理想 → 排查与修改 → 正式版结果”的过程。

4.1 初版存在的问题

1. **Subgradient** 在真实数据上出现数值不稳定。初版在 **diabetes** 上一度出现 `nan`。
2. 日志中出现大量 **RuntimeWarning**。虽然很多结果数值本身正常, 但日志不够干净, 不适合后续汇报展示。
3. 相变分析初版成功率全为 0。这使得“成功率曲线”本身不可解释。
4. 中等规模主实验中, 初始选取的 $\lambda = 0.05$ 虽然误差较低, 但解偏稠密, 不利于展示 **Lasso** 的稀疏恢复特性。

4.2 对应修正

1. 对 Subgradient 的步长做了 Lipschitz 尺度归一化，使其从“数值发散”调整为“可以运行但收敛慢的 baseline”。
2. 对关键矩阵乘法加入安全封装，清理误导性警告。
3. 主实验参数从单纯追求较小误差，调整为更利于展示稀疏性的配置，即在合成数据正式主实验中采用 $\lambda = 0.2$ 。
4. 相变分析新增两种成功标准：
 - 严格标准：支撑集完全一致；
 - 宽松标准：命中至少 80% 的真实非零位置。
5. 相变分析还调整为更适合观察趋势的实验规模： $m = 120, n = 300, s = 10$ 。

5 已完成实验总览

到目前为止，已经完成以下实验：

1. 小规模合成数据基线实验
2. 中等规模合成数据主实验
3. λ 敏感性分析
4. ρ 敏感性分析
5. 噪声强度实验
6. 多随机种子重复实验
7. 三档规模对比实验
8. 正则化路径可视化
9. 相变分析（严格版与宽松版）
10. 真实数据实验：diabetes
11. 真实数据实验：wine_red
12. 真实数据实验：Communities and Crime
13. sklearn Lasso 对照验证

6 实验一：小规模合成数据基线实验

6.1 实验目的

该实验用于：

- 验证四种算法都能正常运行；
- 展示基础的收敛速度差异；
- 画出收敛曲线和系数恢复图。

6.2 实验设置

- $m = 80$
- $n = 200$
- 稀疏度 $s = 10$
- 噪声水平 $\sigma = 0.05$
- $\lambda = 0.05$
- $\rho = 1$

6.3 主要现象

- Subgradient 产生的解几乎不稀疏；
- ISTA、FISTA、ADMM 都能得到明显更稀疏的解；
- ADMM 的迭代次数显著少于其他方法。

7 实验二：中等规模合成数据主实验

7.1 实验目的

该实验是本项目最核心的正式主实验，主要用于：

- 在更高维稀疏场景下比较四种算法；
- 形成后续参数分析和噪声分析的统一主设置；
- 作为期末作业报告中的主结果来源。

7.2 实验设置

- $m = 150$
- $n = 500$
- 稀疏度 $s = 20$
- 噪声水平 $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 最大迭代次数 800

7.3 为什么最终采用 $\lambda = 0.2$

在中等规模实验的初版中，我们比较了多个 λ 。结果表明：

- $\lambda = 0.05$ 时恢复误差更低，但恢复出来的解偏稠密；
- $\lambda = 0.2$ 时非零元素个数更接近真实稀疏度 20，更适合展示 Lasso 稀疏恢复现象。

因此，为了服务“期末作业展示”的目的，而不只是追求单一数值误差最小，我们把 $\lambda = 0.2$ 定为正式主实验参数。

7.4 正式主实验结果

算法	recovery_error	nnz	iter	备注
Subgradient	1.248809	499	800	几乎不稀疏
ISTA	1.067482	26	241	稀疏恢复较好
FISTA	1.067467	26	254	与 ISTA 接近
ADMM	1.067471	26	80	收敛最快




图 1: 合成数据正式主实验的收敛曲线。该图展示了四种算法在中等规模高维稀疏恢复设置下的目标函数下降过程。




图 2: 合成数据正式主实验中的真实系数与恢复系数对比图。可以看到 Subgradient 基本未产生稀疏解，而 ISTA、FISTA 和 ADMM 都恢复出了接近真实稀疏结构的结果。

7.5 结论

1. Subgradient 作为 baseline 效果最差，几乎无法产生理想稀疏解；
2. ISTA、FISTA、ADMM 都能恢复出接近真实稀疏度的解；
3. ADMM 在迭代次数上明显占优，是该设置下最突出的算法。

8 实验三： λ 敏感性分析

8.1 实验目的

研究正则化参数 λ 对以下指标的影响：

- 恢复误差
- 解的稀疏性
- 收敛速度

8.2 实验设置

固定中等规模场景：

- $m = 150$
- $n = 500$
- 稀疏度 $s = 20$
- $\sigma = 0.05$
- $\rho = 1$

考察的 λ 为：

0.01, 0.05, 0.1, 0.2, 0.5

8.3 主要观察

- $\lambda = 0.01$ 时解非常稠密；
- $\lambda = 0.05$ 时恢复误差较低，但非零个数偏大；
- $\lambda = 0.2$ 时稀疏性更接近真实稀疏结构；
- $\lambda = 0.5$ 时出现过度收缩，误差明显变大。

8.4 结论

该实验清楚展示了 Lasso 的核心权衡：较小的 λ 利于拟合精度，较大的 λ 利于稀疏恢复。正式主实验最终采用 $\lambda = 0.2$ ，是出于“更适合展示稀疏结构”的考虑。

9 实验四： ρ 敏感性分析

9.1 实验目的

研究 ADMM 参数 ρ 对收敛速度和最终结果的影响。

9.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho \in \{0.1, 0.5, 1, 5, 10\}$

9.3 主要结果

ρ	ADMM iter	说明
0.1	726	收敛很慢
0.5	149	明显改善
1	80	最快
5	185	再次变慢
10	376	明显变慢

9.4 结论

不同 ρ 对最终恢复误差影响不大，但对收敛速度影响显著。当前实验设置下， $\rho = 1$ 最合适。

10 实验五：噪声强度实验

10.1 实验目的

考察观测噪声水平对稀疏恢复难度的影响。

10.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\lambda = 0.2$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10\}$

10.3 主要结果

以 ADMM 为例：

σ	recovery_error	nnz
0.00	1.058223	17
0.01	1.056204	19
0.05	1.067471	26
0.10	1.301248	50

10.4 结论

噪声越大，恢复误差越大，恢复出的解越不稀疏，说明噪声会显著破坏对真实稀疏结构的识别能力。

11 实验六：多随机种子重复实验

11.1 实验目的

前面的主实验大多基于单个随机种子。为了减少单次随机生成数据带来的偶然性，我们进一步在多个随机种子下重复主实验，并统计各指标的均值与标准差。

11.2 实验设置

- 主实验参数保持不变：
 - $m = 150$
 - $n = 500$
 - 稀疏度 $s = 20$

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 随机种子取 $\{0, 1, 2, 3, 4\}$
- 记录指标：
 - 恢复误差均值与标准差
 - 非零元素个数均值与标准差
 - 迭代次数均值与标准差

11.3 实验结果

算法	recovery_error_mean	nnz_mean	iter_mean
ADMM	0.934555	21.4	81.8
FISTA	0.934569	21.4	215.0
ISTA	0.934565	21.4	229.6
Subgradient	1.120904	499.2	800.0




图 3: 多随机种子重复实验下, 各算法平均迭代次数对比。该图用于说明主实验结论并非单次随机实验的偶然现象。

11.4 结果分析

1. ADMM、ISTA、FISTA 在恢复误差和稀疏度上都较为稳定, 说明主实验结论不是偶然现象;

2. ADMM 的平均迭代次数显著低于 ISTA 和 FISTA;
3. Subgradient 即使在重复实验下仍然表现最差, 说明其劣势是稳定存在的, 而不是某一次随机实验造成的。

11.5 结论

重复实验显著增强了结果的可信度, 也使本项目从“单次演示实验”提升为“具有统计稳定性分析”的期末作业。

12 实验七：三档规模对比实验

12.1 实验目的

研究问题规模增大时, 各算法的恢复误差、稀疏性和收敛速度如何变化。相比只增大某一个参数, 三档规模对比更能系统展示算法在高维场景下的适应性。

12.2 实验设置

固定:

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$

三档规模分别为:

- 小规模: $m = 80, n = 200, s = 10$
- 中规模: $m = 150, n = 500, s = 20$
- 大规模: $m = 300, n = 1000, s = 30$

12.3 实验结果

规模	算法	recovery_error	nnz	iter
80/200/10	ADMM	0.578516	7	70
80/200/10	ISTA	0.578516	7	97
80/200/10	FISTA	0.578516	7	117
80/200/10	Subgradient	0.582503	200	800
150/500/20	ADMM	1.067471	26	80
150/500/20	ISTA	1.067482	26	241
150/500/20	FISTA	1.067467	26	254
150/500/20	Subgradient	1.248809	499	800
300/1000/30	ADMM	1.235796	31	84
300/1000/30	ISTA	1.235805	31	221
300/1000/30	FISTA	1.235818	31	198
300/1000/30	Subgradient	1.393068	1000	800




图 4: 三档规模实验下各算法迭代次数变化图。随着问题规模从 200 维扩展到 1000 维, ADMM 仍保持较低的迭代成本。

12.4 结果分析

1. 随着问题维度从 200 增长到 1000, ADMM、ISTA、FISTA 的恢复误差有所上升, 这是更高维问题更困难的自然表现;
2. 在三档规模下, ADMM 与 ISTA/FISTA 的恢复误差几乎一致, 说明它并未牺牲解质量;

3. ADMM 在三档规模下的迭代次数始终较低，分别为 70、80、84，展现出较好的规模适应性；
4. Subgradient 在所有规模下都表现最差，且始终跑满最大迭代次数。

12.5 结论

三档规模实验表明，随着问题规模增大，ADMM 仍然能够在保证解质量的同时保持较低的迭代成本，这进一步支撑了其在高维稀疏恢复问题中的效率优势。

13 实验八：正则化路径可视化

13.1 实验目的

观察“所有特征系数随 λ 变化的路径”，直观展示 Lasso 如何通过增大正则化强度逐步压缩系数。

13.2 实验设置

- 合成数据
- 求解器：ADMM
- $\lambda \in \{0.01, 0.02, 0.05, 0.1, 0.2, 0.5, 1.0\}$

13.3 结果解释

随着 λ 增大，越来越多的特征系数逐渐向 0 收缩，路径图可以清楚展示 Lasso 的稀疏化机制。这项实验已经满足最初方案中的“正则化路径可视化”设想。




图 5: ADMM 对应的正则化路径图。随着 λ 增大，更多系数逐渐收缩到 0，直观展示了 Lasso 的特征选择与稀疏化机制。

14 实验九：相变分析

14.1 初版问题

最开始，相变分析采用更高维、更严格设置，得到的成功率全部为 0，无法形成有效曲线。

14.2 改进后的正式设置

为得到更有解释性的相变趋势，我们采用：

- $m = 120$
- $n = 300$
- 稀疏度 $s = 10$
- $\lambda = 0.1$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10, 0.20\}$
- 每个噪声水平重复 10 次

14.3 两种成功标准

1. **严格标准 (exact)**: 恢复出的支撑集与真实支撑集完全一致才算成功;
2. **宽松标准 (relaxed)**: 命中至少 80% 的真实非零位置即视为成功。

14.4 严格版结果

- $\sigma = 0.00$ 时成功率约 0.3
- $\sigma = 0.01$ 时成功率约 0.5
- $\sigma \geq 0.05$ 时成功率降为 0

14.5 宽松版结果

- $\sigma = 0.00, 0.01, 0.05, 0.10$ 时成功率接近 1.0
- $\sigma = 0.20$ 时成功率约 0.9





图 6: 相变分析结果。左图为严格成功标准，右图为宽松成功标准。两种口径都表明：噪声越大，恢复成功率越低。

14.6 结论

严格标准下，仅低噪声时才有较明显的完全恢复概率；宽松标准下，算法在低到中等噪声下仍能恢复大部分真实非零位置。该实验现已能够支撑“相变分析”的汇报内容，同时也反映出我们对初版不理想实验结果所做的修正。

15 实验十：真实数据实验

15.1 真实数据一：diabetes

15.1.1 实验目的

验证算法在小规模真实回归任务中的预测误差和收敛效率。

15.1.2 结果特点

- 四种算法的预测误差接近；
- ADMM 收敛较快；
- 修正步长后，Subgradient 可以稳定运行。

15.2 真实数据二：wine_red

15.2.1 实验目的

作为第二个真实回归数据集，验证结果是否在另一个数据集上仍然成立。

15.2.2 实验设置

使用 UCI Wine Quality 红酒数据集，目标变量为 `quality`，其余数值列作为特征。

15.2.3 结果特点

- $\lambda = 0.05$ 与 $\lambda = 0.2$ 的结果差异很小；
- 四种算法预测误差非常接近；
- ADMM 的迭代次数最少，效率优势清晰；
- Subgradient 虽然能运行，但整体效率不如其他方法。

15.3 真实数据三：Communities and Crime

15.3.1 实验目的

将实验扩展到一个更复杂的高维真实回归数据集，用于验证 Lasso 及其优化算法在“存在缺失值、需要清洗、特征维度较高”的实际场景中的表现。

15.3.2 数据特点

- 原始数据包含 1994 个样本、128 个属性；
- 存在缺失值；
- 包含若干 ID/名称类非预测字段；
- 目标变量为 `ViolentCrimesPerPop`。

15.3.3 清洗流程

为保证可用于回归实验，我们采用了以下清洗流程：

1. 使用 `communities.names` 恢复列名；
2. 将 `?` 视为缺失值；
3. 删除非预测列：`state`, `county`, `community`, `communityname`, `fold`；
4. 删除缺失比例超过 30% 的特征列；
5. 对剩余缺失值使用中位数填补；
6. 划分训练集/测试集，并进行标准化。

清洗后最终保留了 100 个有效特征。

15.3.4 实验结果与分析

我们分别测试了 $\lambda = 0.05, 0.2, 1.0$ 。结果表明：

- 在 $\lambda = 0.05$ 和 $\lambda = 0.2$ 下，模型几乎保留了全部特征，稀疏化效果不明显；
- 当 $\lambda = 1.0$ 时，FISTA 与 ADMM 的非零特征数明显下降到 84 和 83，开始体现较强的稀疏化作用；
- 同时测试误差没有明显恶化，说明在该复杂真实数据上，更强正则化可以在不显著损失泛化性能的情况下提升稀疏性。

15.3.5 结论

Communities and Crime 数据集的价值不在于其特征维度一定高于合成数据，而在于它是真实的、带缺失值的、清洗成本较高的复杂回归数据集。它补充说明了：Lasso 的特征选择作用在复杂真实数据上同样存在，但往往需要更强的正则化参数才能显现。




图 7: Communities and Crime 数据集上的收敛曲线。该图用于展示复杂真实高维回归场景下各算法的优化过程。

16 实验十一：sklearn Lasso 对照验证

16.1 实验目的

为了增强实验结果的可信度，我们额外引入 `sklearn.linear_model.Lasso` 作为参考对照。其作用不是替代我们自己的算法，而是验证自实现的 ADMM、ISTA、FISTA 在代表性场景下是否与成熟库实现具有一致趋势。

16.2 为什么只做少量对照而不是全量对照

- `sklearn Lasso` 的主要作用是“参考验证”，而不是本项目的核心比较对象；
- 因此我们只在两个最有代表性的场景做对照：
 - 合成数据正式主实验；
 - Communities and Crime 复杂真实数据实验。

16.3 合成数据主实验对照结果

在正式主实验设置下 ($m = 150, n = 500, s = 20, \sigma = 0.05, \lambda = 0.2, \rho = 1$)，得到：

- FISTA: recovery error = 1.067467, nnz = 26
- ADMM: recovery error = 1.067471, nnz = 26
- sklearn Lasso: recovery error = 1.067471, nnz = 26

这说明在正式主实验中，成熟库实现与自实现的结构化方法几乎完全一致。

16.4 Communities and Crime 对照结果

在 Communities and Crime 数据集上，取 $\lambda = 1.0$ 时：

- FISTA: test mse = 0.308764, nnz = 84
- ADMM: test mse = 0.308941, nnz = 83
- sklearn Lasso: test mse = 0.308995, nnz = 85

这说明在复杂真实高维数据上，自实现算法与 `sklearn Lasso` 也保持了非常接近的结果。

16.5 结论

`sklearn Lasso` 对照验证表明：本项目中自实现的 ADMM、ISTA、FISTA 与成熟库实现结果趋势一致，从而增强了实验结论的可信度。

17 当前总体结论

综合目前已经完成的实验，可以得到以下核心结论：

1. Subgradient 作为 baseline，整体收敛慢、稀疏性差，在合成数据上的表现明显弱于其他三种方法；
2. ISTA、FISTA、ADMM 都可以有效求解 Lasso，其中 ADMM 在当前实验中迭代次数通常最少；
3. λ 控制拟合误差与稀疏性的平衡；
4. ρ 主要影响 ADMM 的收敛速度，而不是最终解；
5. 噪声越大，稀疏恢复越困难；
6. 多随机种子重复实验表明主结论具有稳定性，不是单次随机实验的偶然结果；
7. 三档规模实验表明 ADMM 在问题规模增大时仍保持较好的效率优势；
8. 在真实数据上，结构化方法的预测精度通常接近，但 ADMM 仍具有较强的收敛效率优势；
9. 在更复杂的 Communities and Crime 数据集上，Lasso 的稀疏化作用需要更强的正则化参数才能明显显现；

10. `sklearn` Lasso 对照验证表明，自实现结构化方法与成熟库实现结果高度一致，增强了实验可信度；
11. 正则化路径和相变分析补足了本项目作为 Lasso 优化实验的完整性。

18 结论与展望

本文围绕 Lasso 回归中的优化求解问题，系统比较了 Subgradient、ISTA、FISTA 和 ADMM 四种算法，并在合成数据与真实数据上完成了较为完整的实验验证。综合实验结果，可以得到以下结论：

1. 在合成数据主实验中，ISTA、FISTA 和 ADMM 都能恢复出接近真实稀疏度的解，而 Subgradient 作为直接处理非光滑项的 baseline，表现明显较差。
2. 在保持恢复误差接近的前提下，ADMM 的迭代次数通常最少，因此在本项目中体现出较强的效率优势。
3. 正则化参数 λ 决定了拟合精度与稀疏性之间的权衡；较小的 λ 更利于减小误差，而较大的 λ 更利于恢复稀疏结构。
4. ADMM 参数 ρ 对最终解影响较小，但对收敛速度影响显著，本实验设置下 $\rho = 1$ 表现最佳。
5. 噪声越大，恢复误差越大，恢复出的解越不稀疏，说明观测噪声会显著削弱对真实稀疏结构的识别能力。
6. 多随机种子重复实验与三档规模实验说明：本项目主结论不仅稳定，而且在更大问题规模下仍然成立。
7. 在真实数据上，几种结构化方法的预测误差通常比较接近；其中 Communities and Crime 进一步说明，在复杂真实高维数据上，往往需要更强的正则化参数才能显著体现 Lasso 的特征选择作用。
8. `sklearn` Lasso 对照实验表明，自实现的 ADMM、ISTA、FISTA 与成熟库结果高度一致，从而增强了实验结论的可信度。

未来如果继续扩展该课题，可以考虑以下方向：

- 对更多真实高维回归数据集进行验证；
- 引入更系统的超参数选择方法，如交叉验证；
- 将 Lasso 扩展到 Elastic Net、Group Lasso 等更复杂的稀疏建模任务；
- 从理论角度补充不同算法的收敛性质与复杂度分析。