

# Lasso 回归优化实验初步报告

供组内对齐进度与后续 PPT/终稿写作使用

2026 年 6 月 5 日

## 1 文档用途说明

这不是最终提交版报告，而是一份组内流转的初步说明稿，目的是让未直接参与实验实现的组员也能快速理解：

1. 课题做的是是什么；
2. 目前已经完成了哪些实验；
3. 每个实验的具体参数设置是什么；
4. 实验过程中遇到了哪些问题、如何修正；
5. 后续写正式报告和制作 PPT 时还需要补哪些整理工作。

## 2 课题背景与研究目标

本课题围绕 Lasso 回归中的优化问题展开，重点比较以下四种算法在稀疏回归任务上的表现：

- Subgradient Descent
- ISTA
- FISTA
- ADMM

Lasso 模型写作

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

其中，第一项刻画拟合误差，第二项通过  $L_1$  正则诱导稀疏性。

本项目的研究目标包括：

1. 在合成稀疏数据上比较四种算法的恢复误差、稀疏性和收敛速度；
2. 分析正则化参数  $\lambda$  与 ADMM 参数  $\rho$  的影响；
3. 分析噪声强度对稀疏恢复的影响；
4. 在真实数据集上验证算法在实际回归任务中的预测表现；
5. 通过正则化路径和相变分析补足 Lasso 主题下更完整的实验层次。

## 3 算法说明

### 3.1 Subgradient Descent

该方法直接对非光滑目标函数做次梯度下降，作为 baseline。它实现简单，但步长敏感、收敛慢，在本实验中主要用于说明直接处理非光滑项的局限性。

### 3.2 ISTA

ISTA 是经典近端梯度法。每一步先对光滑项做梯度下降，再对  $L_1$  项施加软阈值算子，因此能够更自然地处理 Lasso 问题。

### 3.3 FISTA

FISTA 是 ISTA 的加速版本，通过 Nesterov 动量项提升收敛速度。理论和实践上都应优于或不差于 ISTA。

### 3.4 ADMM

ADMM 通过变量分裂把 Lasso 问题拆分成二次子问题与软阈值子问题，适合处理“光滑项 + 非光滑项”的组合优化问题。本课题中，ADMM 是最核心的方法之一。

## 4 数据集设置

### 4.1 合成数据

合成数据用于主实验，因为真实稀疏解  $x^*$  已知，可以直接评估：

- 恢复误差  $\|\hat{x} - x^*\|_2$
- 非零元素个数
- 支撑集恢复是否成功

合成数据构造方式如下：

1. 生成高斯随机矩阵  $A$ ；
2. 按列归一化，减弱特征尺度不一致带来的影响；
3. 生成稀疏真实信号  $x^*$ ，仅保留少数非零元素；
4. 加入高斯噪声，构造观测  $b = Ax^* + \varepsilon$ 。

## 4.2 真实数据

目前使用了三个真实回归数据集：

- **diabetes**：来自 `sklearn`，规模较小，适合作为真实数据补充实验；
- **winequality-red.csv**：来自 UCI Wine Quality 数据集，使用红酒子集作为第二个真实数据验证场景。
- **Communities and Crime**：来自 UCI，存在缺失值，特征更多，适合作为复杂真实高维回归场景的补充实验。

原本尝试接入 **California Housing**，但运行中遇到远程下载的 HTTP 403 问题，因此最终采用了本地可控的 **wine\_red** 与 **Communities and Crime** 数据。

需要特别说明的是：合成数据与真实数据并不是做完全相同的实验，而是有明确分工：

- **合成数据**：负责机制分析。因为知道真实稀疏解，所以可以做恢复误差、支撑集恢复、相变分析、噪声实验和规模扩展实验。
- **真实数据**：负责应用验证。因为真实数据中不知道真实系数，所以重点考察预测误差、稀疏性和收敛效率。

# 5 实验实现中的修正与改进

这一部分很重要，因为本项目并不是一一次性得到完美结果，而是经历了“初版结果不理想 → 排查与修改 → 正式版结果”的过程。

## 5.1 初版存在的问题

1. **Subgradient** 在真实数据上出现数值不稳定。初版在 **diabetes** 上一度出现 **nan**。
2. 日志中出现大量 **RuntimeWarning**。虽然很多结果数值本身正常，但日志不够干净，不适合后续汇报展示。
3. 相变分析初版成功率全为 0。这使得“成功率曲线”本身不可解释。

4. 中等规模主实验中，初始选取的  $\lambda = 0.05$  虽然误差较低，但解偏稠密，不利于展示 Lasso 的稀疏恢复特性。

## 5.2 对应修正

1. 对 Subgradient 的步长做了 Lipschitz 尺度归一化，使其从“数值发散”调整为“可以运行但收敛慢的 baseline”。
2. 对关键矩阵乘法加入安全封装，清理误导性警告。
3. 主实验参数从单纯追求较小误差，调整为更利于展示稀疏性的配置，即在合成数据正式主实验中采用  $\lambda = 0.2$ 。
4. 相变分析新增两种成功标准：
  - 严格标准：支撑集完全一致；
  - 宽松标准：命中至少 80% 的真实非零位置。
5. 相变分析还调整为更适合观察趋势的实验规模： $m = 120, n = 300, s = 10$ 。

## 6 已完成实验总览

到目前为止，已经完成以下实验：

1. 小规模合成数据基线实验
2. 中等规模合成数据主实验
3.  $\lambda$  敏感性分析
4.  $\rho$  敏感性分析
5. 噪声强度实验
6. 多随机种子重复实验
7. 三档规模对比实验
8. 正则化路径可视化
9. 相变分析（严格版与宽松版）
10. 真实数据实验：diabetes
11. 真实数据实验：wine\_red
12. 真实数据实验：Communities and Crime
13. sklearn Lasso 对照验证

## 7 实验一：小规模合成数据基线实验

### 7.1 实验目的

该实验用于：

- 验证四种算法都能正常运行；
- 展示基础的收敛速度差异；
- 画出收敛曲线和系数恢复图。

### 7.2 实验设置

- $m = 80$
- $n = 200$
- 稀疏度  $s = 10$
- 噪声水平  $\sigma = 0.05$
- $\lambda = 0.05$
- $\rho = 1$

### 7.3 主要现象

- Subgradient 产生的解几乎不稀疏；
- ISTA、FISTA、ADMM 都能得到明显更稀疏的解；
- ADMM 的迭代次数显著少于其他方法。

## 8 实验二：中等规模合成数据主实验

### 8.1 实验目的

该实验是本项目最核心的正式主实验，主要用于：

- 在更高维稀疏场景下比较四种算法；
- 形成后续参数分析和噪声分析的统一主设置；
- 作为期末作业报告中的主结果来源。

## 8.2 实验设置

- $m = 150$
- $n = 500$
- 稀疏度  $s = 20$
- 噪声水平  $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 最大迭代次数 800

## 8.3 为什么最终采用 $\lambda = 0.2$

在中等规模实验的初版中，我们比较了多个  $\lambda$ 。结果表明：

- $\lambda = 0.05$  时恢复误差更低，但恢复出来的解偏稠密；
- $\lambda = 0.2$  时非零元素个数更接近真实稀疏度 20，更适合展示 Lasso 稀疏恢复现象。

因此，为了服务“期末作业展示”的目的，而不只是追求单一数值误差最小，我们把  $\lambda = 0.2$  定为正式主实验参数。

## 8.4 正式主实验结果

| 算法          | recovery_error | nnz | iter | 备注        |
|-------------|----------------|-----|------|-----------|
| Subgradient | 1.248809       | 499 | 800  | 几乎不稀疏     |
| ISTA        | 1.067482       | 26  | 241  | 稀疏恢复较好    |
| FISTA       | 1.067467       | 26  | 254  | 与 ISTA 接近 |
| ADMM        | 1.067471       | 26  | 80   | 收敛最快      |

## 8.5 结论

1. Subgradient 作为 baseline 效果最差，几乎无法产生理想稀疏解；
2. ISTA、FISTA、ADMM 都能恢复出接近真实稀疏度的解；
3. ADMM 在迭代次数上明显占优，是该设置下最突出的算法。

## 9 实验三： $\lambda$ 敏感性分析

### 9.1 实验目的

研究正则化参数  $\lambda$  对以下指标的影响：

- 恢复误差
- 解的稀疏性
- 收敛速度

### 9.2 实验设置

固定中等规模场景：

- $m = 150$
- $n = 500$
- 稀疏度  $s = 20$
- $\sigma = 0.05$
- $\rho = 1$

考察的  $\lambda$  为：

0.01, 0.05, 0.1, 0.2, 0.5

### 9.3 主要观察

- $\lambda = 0.01$  时解非常稠密；
- $\lambda = 0.05$  时恢复误差较低，但非零个数偏大；
- $\lambda = 0.2$  时稀疏性更接近真实稀疏结构；
- $\lambda = 0.5$  时出现过度收缩，误差明显变大。

### 9.4 结论

该实验清楚展示了 Lasso 的核心权衡：较小的  $\lambda$  利于拟合精度，较大的  $\lambda$  利于稀疏恢复。正式主实验最终采用  $\lambda = 0.2$ ，是出于“更适合展示稀疏结构”的考虑。

## 10 实验四： $\rho$ 敏感性分析

### 10.1 实验目的

研究 ADMM 参数  $\rho$  对收敛速度和最终结果的影响。

### 10.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho \in \{0.1, 0.5, 1, 5, 10\}$

### 10.3 主要结果

| $\rho$ | ADMM iter | 说明   |
|--------|-----------|------|
| 0.1    | 726       | 收敛很慢 |
| 0.5    | 149       | 明显改善 |
| 1      | 80        | 最快   |
| 5      | 185       | 再次变慢 |
| 10     | 376       | 明显变慢 |

### 10.4 结论

不同  $\rho$  对最终恢复误差影响不大，但对收敛速度影响显著。当前实验设置下， $\rho = 1$  最合适。

## 11 实验五：噪声强度实验

### 11.1 实验目的

考察观测噪声水平对稀疏恢复难度的影响。

## 11.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\lambda = 0.2$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10\}$

## 11.3 主要结果

以 ADMM 为例：

| $\sigma$ | recovery_error | nnz |
|----------|----------------|-----|
| 0.00     | 1.058223       | 17  |
| 0.01     | 1.056204       | 19  |
| 0.05     | 1.067471       | 26  |
| 0.10     | 1.301248       | 50  |

## 11.4 结论

噪声越大，恢复误差越大，恢复出的解越不稀疏，说明噪声会显著破坏对真实稀疏结构的识别能力。

# 12 实验六：多随机种子重复实验

## 12.1 实验目的

前面的主实验大多基于单个随机种子。为了减少单次随机生成数据带来的偶然性，我们进一步在多个随机种子下重复主实验，并统计各指标的均值与标准差。

## 12.2 实验设置

- 主实验参数保持不变：
  - $m = 150$
  - $n = 500$
  - 稀疏度  $s = 20$

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 随机种子取  $\{0, 1, 2, 3, 4\}$
- 记录指标：
  - 恢复误差均值与标准差
  - 非零元素个数均值与标准差
  - 迭代次数均值与标准差

### 12.3 实验结果

| 算法          | recovery_error_mean | nnz_mean | iter_mean |
|-------------|---------------------|----------|-----------|
| ADMM        | 0.934555            | 21.4     | 81.8      |
| FISTA       | 0.934569            | 21.4     | 215.0     |
| ISTA        | 0.934565            | 21.4     | 229.6     |
| Subgradient | 1.120904            | 499.2    | 800.0     |

### 12.4 结果分析

1. ADMM、ISTA、FISTA 在恢复误差和稀疏度上都较为稳定，说明主实验结论不是偶然现象；
2. ADMM 的平均迭代次数显著低于 ISTA 和 FISTA；
3. Subgradient 即使在重复实验下仍然表现最差，说明其劣势是稳定存在的，而不是某一次随机实验造成的。

### 12.5 结论

重复实验显著增强了结果的可信度，也使本项目从“单次演示实验”提升为“具有统计稳定性分析”的期末作业。

## 13 实验七：三档规模对比实验

### 13.1 实验目的

研究问题规模增大时，各算法的恢复误差、稀疏性和收敛速度如何变化。相比只增大某一个参数，三档规模对比更能系统展示算法在高维场景下的适应性。

## 13.2 实验设置

固定：

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$

三档规模分别为：

- 小规模：  $m = 80, n = 200, s = 10$
- 中规模：  $m = 150, n = 500, s = 20$
- 大规模：  $m = 300, n = 1000, s = 30$

## 13.3 实验结果

| 规模          | 算法          | recovery_error | nnz  | iter |
|-------------|-------------|----------------|------|------|
| 80/200/10   | ADMM        | 0.578516       | 7    | 70   |
| 80/200/10   | ISTA        | 0.578516       | 7    | 97   |
| 80/200/10   | FISTA       | 0.578516       | 7    | 117  |
| 80/200/10   | Subgradient | 0.582503       | 200  | 800  |
| 150/500/20  | ADMM        | 1.067471       | 26   | 80   |
| 150/500/20  | ISTA        | 1.067482       | 26   | 241  |
| 150/500/20  | FISTA       | 1.067467       | 26   | 254  |
| 150/500/20  | Subgradient | 1.248809       | 499  | 800  |
| 300/1000/30 | ADMM        | 1.235796       | 31   | 84   |
| 300/1000/30 | ISTA        | 1.235805       | 31   | 221  |
| 300/1000/30 | FISTA       | 1.235818       | 31   | 198  |
| 300/1000/30 | Subgradient | 1.393068       | 1000 | 800  |

## 13.4 结果分析

1. 随着问题维度从 200 增长到 1000，ADMM、ISTA、FISTA 的恢复误差有所上升，这是更高维问题更困难的自然表现；
2. 在三档规模下，ADMM 与 ISTA/FISTA 的恢复误差几乎一致，说明它并未牺牲解质量；
3. ADMM 在三档规模下的迭代次数始终较低，分别为 70、80、84，展现出较好的规模适应性；

4. Subgradient 在所有规模下都表现最差，且始终跑满最大迭代次数。

### 13.5 结论

三档规模实验表明，随着问题规模增大，ADMM 仍然能够在保证解质量的同时保持较低的迭代成本，这进一步支撑了其在高维稀疏恢复问题中的效率优势。

## 14 实验八：正则化路径可视化

### 14.1 实验目的

观察“所有特征系数随  $\lambda$  变化的路径”，直观展示 Lasso 如何通过增大正则化强度逐步压缩系数。

### 14.2 实验设置

- 合成数据
- 求解器：ADMM
- $\lambda \in \{0.01, 0.02, 0.05, 0.1, 0.2, 0.5, 1.0\}$

### 14.3 结果解释

随着  $\lambda$  增大，越来越多的特征系数逐渐向 0 收缩，路径图可以清楚展示 Lasso 的稀疏机制。这项实验已经满足最初方案中的“正则化路径可视化”设想。

## 15 实验九：相变分析

### 15.1 初版问题

最开始，相变分析采用更高维、更严格设置，得到的成功率全部为 0，无法形成有效曲线。

### 15.2 改进后的正式设置

为得到更有解释性的相变趋势，我们采用：

- $m = 120$
- $n = 300$
- 稀疏度  $s = 10$

- $\lambda = 0.1$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10, 0.20\}$
- 每个噪声水平重复 10 次

### 15.3 两种成功标准

1. **严格标准 (exact)**: 恢复出的支撑集与真实支撑集完全一致才算成功;
2. **宽松标准 (relaxed)**: 命中至少 80% 的真实非零位置即视为成功。

### 15.4 严格版结果

- $\sigma = 0.00$  时成功率约 0.3
- $\sigma = 0.01$  时成功率约 0.5
- $\sigma \geq 0.05$  时成功率降为 0

### 15.5 宽松版结果

- $\sigma = 0.00, 0.01, 0.05, 0.10$  时成功率接近 1.0
- $\sigma = 0.20$  时成功率约 0.9

### 15.6 结论

严格标准下, 仅低噪声时才有较明显的完全恢复概率; 宽松标准下, 算法在低到中等噪声下仍能恢复大部分真实非零位置。该实验现已能够支撑“相变分析”的汇报内容, 同时也反映出我们对初版不理想实验结果所做的修正。

## 16 实验十：真实数据实验

### 16.1 真实数据一：diabetes

#### 16.1.1 实验目的

验证算法在小规模真实回归任务中的预测误差和收敛效率。

### 16.1.2 结果特点

- 四种算法的预测误差接近；
- ADMM 收敛较快；
- 修正步长后，Subgradient 可以稳定运行。

## 16.2 真实数据二：wine\_red

### 16.2.1 实验目的

作为第二个真实回归数据集，验证结果是否在另一个数据集上仍然成立。

### 16.2.2 实验设置

使用 UCI Wine Quality 红酒数据集，目标变量为 `quality`，其余数值列作为特征。

### 16.2.3 结果特点

- $\lambda = 0.05$  与  $\lambda = 0.2$  的结果差异很小；
- 四种算法预测误差非常接近；
- ADMM 的迭代次数最少，效率优势清晰；
- Subgradient 虽然能运行，但整体效率不如其他方法。

## 16.3 真实数据三：Communities and Crime

### 16.3.1 实验目的

将实验扩展到一个更复杂的高维真实回归数据集，用于验证 Lasso 及其优化算法在“存在缺失值、需要清洗、特征维度较高”的实际场景中的表现。

### 16.3.2 数据特点

- 原始数据包含 1994 个样本、128 个属性；
- 存在缺失值；
- 包含若干 ID/名称类非预测字段；
- 目标变量为 `ViolentCrimesPerPop`。

### 16.3.3 清洗流程

为保证可用于回归实验，我们采用了以下清洗流程：

1. 使用 `communities.names` 恢复列名；
2. 将 `?` 视为缺失值；
3. 删除非预测列：`state`, `county`, `community`, `communityname`, `fold`；
4. 删除缺失比例超过 30% 的特征列；
5. 对剩余缺失值使用中位数填补；
6. 划分训练集/测试集，并进行标准化。

清洗后最终保留了 100 个有效特征。

### 16.3.4 实验结果与分析

我们分别测试了  $\lambda = 0.05, 0.2, 1.0$ 。结果表明：

- 在  $\lambda = 0.05$  和  $\lambda = 0.2$  下，模型几乎保留了全部特征，稀疏化效果不明显；
- 当  $\lambda = 1.0$  时，FISTA 与 ADMM 的非零特征数明显下降到 84 和 83，开始体现较强的稀疏化作用；
- 同时测试误差没有明显恶化，说明在该复杂真实数据上，更强正则化可以在不显著损失泛化性能的情况下提升稀疏性。

### 16.3.5 结论

Communities and Crime 数据集的价值不在于其特征维度一定高于合成数据，而在于它是真实的、带缺失值的、清洗成本较高的复杂回归数据集。它补充说明了：Lasso 的特征选择作用在复杂真实数据上同样存在，但往往需要更强的正则化参数才能显现。

## 17 实验十一：sklearn Lasso 对照验证

### 17.1 实验目的

为了增强实验结果的可信度，我们额外引入 `sklearn.linear_model.Lasso` 作为参考对照。其作用不是替代我们自己的算法，而是验证自实现的 ADMM、ISTA、FISTA 在代表性场景下是否与成熟库实现具有一致趋势。

## 17.2 为什么只做少量对照而不是全量对照

- `sklearn Lasso` 的主要作用是“参考验证”，而不是本项目的核心比较对象；
- 因此我们只在两个最有代表性的场景做对照：
  - 合成数据正式主实验；
  - `Communities and Crime` 复杂真实数据实验。

## 17.3 合成数据主实验对照结果

在正式主实验设置下 ( $m = 150, n = 500, s = 20, \sigma = 0.05, \lambda = 0.2, \rho = 1$ )，得到：

- FISTA:  $\text{recovery error} = 1.067467, \text{nnz} = 26$
- ADMM:  $\text{recovery error} = 1.067471, \text{nnz} = 26$
- `sklearn Lasso`:  $\text{recovery error} = 1.067471, \text{nnz} = 26$

这说明在正式主实验中，成熟库实现与自实现的结构化方法几乎完全一致。

## 17.4 `Communities and Crime` 对照结果

在 `Communities and Crime` 数据集上，取  $\lambda = 1.0$  时：

- FISTA:  $\text{test mse} = 0.308764, \text{nnz} = 84$
- ADMM:  $\text{test mse} = 0.308941, \text{nnz} = 83$
- `sklearn Lasso`:  $\text{test mse} = 0.308995, \text{nnz} = 85$

这说明在复杂真实高维数据上，自实现算法与 `sklearn Lasso` 也保持了非常接近的结果。

## 17.5 结论

`sklearn Lasso` 对照验证表明：本项目中自实现的 ADMM、ISTA、FISTA 与成熟库实现结果趋势一致，从而增强了实验结论的可信度。

# 18 当前总体结论

综合目前已经完成的实验，可以得到以下核心结论：

1. Subgradient 作为 baseline，整体收敛慢、稀疏性差，在合成数据上的表现明显弱于其他三种方法；

2. ISTA、FISTA、ADMM 都可以有效求解 Lasso，其中 ADMM 在当前实验中迭代次数通常最少；
3.  $\lambda$  控制拟合误差与稀疏性的平衡；
4.  $\rho$  主要影响 ADMM 的收敛速度，而不是最终解；
5. 噪声越大，稀疏恢复越困难；
6. 多随机种子重复实验表明主结论具有稳定性，不是单次随机实验的偶然结果；
7. 三档规模实验表明 ADMM 在问题规模增大时仍保持较好的效率优势；
8. 在真实数据上，结构化方法的预测精度通常接近，但 ADMM 仍具有较强的收敛效率优势；
9. 在更复杂的 Communities and Crime 数据集上，Lasso 的稀疏化作用需要更强的正则化参数才能明显显现；
10. `sklearn` Lasso 对照验证表明，自实现结构化方法与成熟库实现结果高度一致，增强了实验可信度；
11. 正则化路径和相变分析补足了本项目作为 Lasso 优化实验的完整性。

## 19 目前是否足以支撑期末大作业

从实验层次和内容覆盖度看，目前已经足以支撑一份期末小组大作业。原因是：

- 有理论模型；
- 有四种算法；
- 有不同规模的合成数据；
- 有参数分析；
- 有噪声分析；
- 有重复实验稳定性分析；
- 有问题规模扩展分析；
- 有正则化路径；
- 有相变分析；
- 有三个真实数据集验证。

- 有成熟库实现的参考对照验证。

因此，后续工作的重点不应再是盲目扩展实验数量，而应转为：

1. 整理图表；
2. 完善实验分析文字；
3. 组织 PPT 展示逻辑；
4. 统一报告的最终叙述口径。

## 20 后续还需要补什么

目前更需要补的是整理工作，而非额外跑大量新实验。建议后续分工如下：

### 20.1 需要整理的表格

- 四算法主实验对比表
- $\lambda$  敏感性结果表
- $\rho$  敏感性结果表
- 噪声实验结果表
- 真实数据实验结果汇总表 (diabetes、wine\_red、Communities and Crime)
- sklearn Lasso 对照结果表

### 20.2 建议放入正式报告/PPT 的图

- 合成数据收敛曲线图
- 合成数据稀疏恢复图
- 正则化路径图
- 相变分析图（严格版和宽松版至少选一张）
- 一张真实数据结果汇总表

### 20.3 已整理好的图片文件夹

为了方便组员直接写报告和制作 PPT，我们已经把建议优先使用的图片从 `results/` 中复制到单独文件夹 `report_figures/`，并改成了更直观的文件名。该文件夹中的图片不会影响原始实验结果，主要作用是降低组员整理素材时的沟通成本。

当前已整理的代表性图片包括：

- `01_synthetic_main_convergence_curve.png`
- `02_synthetic_main_sparse_recovery_coefficients.png`
- `03_repeat_experiment_mean_iterations.png`
- `04_scale_comparison_iterations.png`
- `05_regularization_path_admm.png`
- `06_phase_transition_exact_success_rate.png`
- `07_phase_transition_relaxed_success_rate.png`
- `08_diabetes_convergence_curve.png`
- `09_wine_red_convergence_curve.png`
- `10_communities_crime_convergence_curve.png`

### 20.4 建议正文优先使用的图片

如果正式报告正文篇幅有限，建议优先选择以下图片：

1. `02_synthetic_main_sparse_recovery_coefficients.png`
2. `01_synthetic_main_convergence_curve.png`
3. `05_regularization_path_admm.png`
4. `06_phase_transition_exact_success_rate.png`
5. `07_phase_transition_relaxed_success_rate.png`
6. `03_repeat_experiment_mean_iterations.png`
7. `04_scale_comparison_iterations.png`

真实数据部分通常不需要把三张收敛曲线都放进正文，更推荐把其结论整理成一张汇总表；如果答辩时需要补图，可优先使用 `10_communities_crime_convergence_curve.png` 作为复杂真实数据代表图。

## 20.5 建议在 PPT 中讲清楚的重点

1. 为什么要研究 Lasso;
2. 为什么要比较这四种算法;
3. 为什么 ADMM 适合该问题;
4. 为什么最终主实验参数选为  $\lambda = 0.2, \rho = 1$ ;
5. 为什么相变分析需要从初版结果进一步修正;
6. 最终三到四条最核心的结论是什么。

## 21 建议的最终报告结构

1. 研究背景与问题定义
2. Lasso 模型与算法介绍
3. 实验设置
4. 合成数据主实验
5. 参数敏感性分析
6. 噪声实验与相变分析
7. 正则化路径分析
8. 真实数据实验
9. 实验中遇到的问题与修正
10. 总结与展望

## 22 给组员的一句话总结

目前实验主体已经完成，且已经从初版不理想结果中修正出一套正式版实验。接下来最重要的工作不是再无控制地扩实验，而是把现有结果整理成清晰的图表、结论和 PPT 叙述。