

Lasso 回归优化实验初步报告

供组内对齐进度与后续 PPT/终稿写作使用

2026 年 6 月 5 日

1 文档用途说明

这不是最终提交版报告，而是一份组内流转的初步说明稿，目的是让未直接参与实验实现的组员也能快速理解：

1. 课题做的是是什么；
2. 目前已经完成了哪些实验；
3. 每个实验的具体参数设置是什么；
4. 实验过程中遇到了哪些问题、如何修正；
5. 后续写正式报告和制作 PPT 时还需要补哪些整理工作。

2 课题背景与研究目标

本课题围绕 Lasso 回归中的优化问题展开，重点比较以下四种算法在稀疏回归任务上的表现：

- Subgradient Descent
- ISTA
- FISTA
- ADMM

Lasso 模型写作

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

其中，第一项刻画拟合误差，第二项通过 L_1 正则诱导稀疏性。

本项目的研究目标包括：

1. 在合成稀疏数据上比较四种算法的恢复误差、稀疏性和收敛速度；
2. 分析正则化参数 λ 与 ADMM 参数 ρ 的影响；
3. 分析噪声强度对稀疏恢复的影响；
4. 在真实数据集上验证算法在实际回归任务中的预测表现；
5. 通过正则化路径和相变分析补足 Lasso 主题下更完整的实验层次。

3 算法说明

3.1 Subgradient Descent

该方法直接对非光滑目标函数做次梯度下降，作为 baseline。它实现简单，但步长敏感、收敛慢，在本实验中主要用于说明直接处理非光滑项的局限性。

3.2 ISTA

ISTA 是经典近端梯度法。每一步先对光滑项做梯度下降，再对 L_1 项施加软阈值算子，因此能够更自然地处理 Lasso 问题。

3.3 FISTA

FISTA 是 ISTA 的加速版本，通过 Nesterov 动量项提升收敛速度。理论和实践上都应优于或不差于 ISTA。

3.4 ADMM

ADMM 通过变量分裂把 Lasso 问题拆分成二次子问题与软阈值子问题，适合处理“光滑项 + 非光滑项”的组合优化问题。本课题中，ADMM 是最核心的方法之一。

4 数据集设置

4.1 合成数据

合成数据用于主实验，因为真实稀疏解 x^* 已知，可以直接评估：

- 恢复误差 $\|\hat{x} - x^*\|_2$
- 非零元素个数
- 支撑集恢复是否成功

合成数据构造方式如下：

1. 生成高斯随机矩阵 A ；
2. 按列归一化，减弱特征尺度不一致带来的影响；
3. 生成稀疏真实信号 x^* ，仅保留少数非零元素；
4. 加入高斯噪声，构造观测 $b = Ax^* + \varepsilon$ 。

4.2 真实数据

目前使用了三个真实回归数据集：

- **diabetes**：来自 `sklearn`，规模较小，适合作为真实数据补充实验；
- **winequality-red.csv**：来自 UCI Wine Quality 数据集，使用红酒子集作为第二个真实数据验证场景。
- **Communities and Crime**：来自 UCI，存在缺失值，特征更多，适合作为复杂真实高维回归场景的补充实验。

原本尝试接入 **California Housing**，但运行中遇到远程下载的 HTTP 403 问题，因此最终采用了本地可控的 **wine_red** 与 **Communities and Crime** 数据。

需要特别说明的是：合成数据与真实数据并不是做完全相同的实验，而是有明确分工：

- **合成数据**：负责机制分析。因为知道真实稀疏解，所以可以做恢复误差、支撑集恢复、相变分析、噪声实验和规模扩展实验。
- **真实数据**：负责应用验证。因为真实数据中不知道真实系数，所以重点考察预测误差、稀疏性和收敛效率。

5 实验实现中的修正与改进

这一部分很重要，因为本项目并不是一次性得到完美结果，而是经历了“初版结果不理想 → 排查与修改 → 正式版结果”的过程。

5.1 初版存在的问题

1. **Subgradient** 在真实数据上出现数值不稳定。初版在 **diabetes** 上一度出现 **nan**。
2. 日志中出现大量 **RuntimeWarning**。虽然很多结果数值本身正常，但日志不够干净，不适合后续汇报展示。
3. 相变分析初版成功率全为 0。这使得“成功率曲线”本身不可解释。

4. 中等规模主实验中，初始选取的 $\lambda = 0.05$ 虽然误差较低，但解偏稠密，不利于展示 Lasso 的稀疏恢复特性。

5.2 对应修正

1. 对 Subgradient 的步长做了 Lipschitz 尺度归一化，使其从“数值发散”调整为“可以运行但收敛慢的 baseline”。
2. 对关键矩阵乘法加入安全封装，清理误导性警告。
3. 主实验参数从单纯追求较小误差，调整为更利于展示稀疏性的配置，即在合成数据正式主实验中采用 $\lambda = 0.2$ 。
4. 相变分析新增两种成功标准：
 - 严格标准：支撑集完全一致；
 - 宽松标准：命中至少 80% 的真实非零位置。
5. 相变分析还调整为更适合观察趋势的实验规模： $m = 120, n = 300, s = 10$ 。

6 已完成实验总览

到目前为止，已经完成以下实验：

1. 小规模合成数据基线实验
2. 中等规模合成数据主实验
3. λ 敏感性分析
4. ρ 敏感性分析
5. 噪声强度实验
6. 多随机种子重复实验
7. 三档规模对比实验
8. 正则化路径可视化
9. 相变分析（严格版与宽松版）
10. 真实数据实验：diabetes
11. 真实数据实验：wine_red
12. 真实数据实验：Communities and Crime

7 实验一：小规模合成数据基线实验

7.1 实验目的

该实验用于：

- 验证四种算法都能正常运行；
- 展示基础的收敛速度差异；
- 画出收敛曲线和系数恢复图。

7.2 实验设置

- $m = 80$
- $n = 200$
- 稀疏度 $s = 10$
- 噪声水平 $\sigma = 0.05$
- $\lambda = 0.05$
- $\rho = 1$

7.3 主要现象

- Subgradient 产生的解几乎不稀疏；
- ISTA、FISTA、ADMM 都能得到明显更稀疏的解；
- ADMM 的迭代次数显著少于其他方法。

8 实验二：中等规模合成数据主实验

8.1 实验目的

该实验是本项目最核心的正式主实验，主要用于：

- 在更高维稀疏场景下比较四种算法；
- 形成后续参数分析和噪声分析的统一主设置；
- 作为期末作业报告中的主结果来源。

8.2 实验设置

- $m = 150$
- $n = 500$
- 稀疏度 $s = 20$
- 噪声水平 $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 最大迭代次数 800

8.3 为什么最终采用 $\lambda = 0.2$

在中等规模实验的初版中，我们比较了多个 λ 。结果表明：

- $\lambda = 0.05$ 时恢复误差更低，但恢复出来的解偏稠密；
- $\lambda = 0.2$ 时非零元素个数更接近真实稀疏度 20，更适合展示 Lasso 稀疏恢复现象。

因此，为了服务“期末作业展示”的目的，而不只是追求单一数值误差最小，我们把 $\lambda = 0.2$ 定为正式主实验参数。

8.4 正式主实验结果

算法	recovery_error	nnz	iter	备注
Subgradient	1.248809	499	800	几乎不稀疏
ISTA	1.067482	26	241	稀疏恢复较好
FISTA	1.067467	26	254	与 ISTA 接近
ADMM	1.067471	26	80	收敛最快

8.5 结论

1. Subgradient 作为 baseline 效果最差，几乎无法产生理想稀疏解；
2. ISTA、FISTA、ADMM 都能恢复出接近真实稀疏度的解；
3. ADMM 在迭代次数上明显占优，是该设置下最突出的算法。

9 实验三： λ 敏感性分析

9.1 实验目的

研究正则化参数 λ 对以下指标的影响：

- 恢复误差
- 解的稀疏性
- 收敛速度

9.2 实验设置

固定中等规模场景：

- $m = 150$
- $n = 500$
- 稀疏度 $s = 20$
- $\sigma = 0.05$
- $\rho = 1$

考察的 λ 为：

0.01, 0.05, 0.1, 0.2, 0.5

9.3 主要观察

- $\lambda = 0.01$ 时解非常稠密；
- $\lambda = 0.05$ 时恢复误差较低，但非零个数偏大；
- $\lambda = 0.2$ 时稀疏性更接近真实稀疏结构；
- $\lambda = 0.5$ 时出现过度收缩，误差明显变大。

9.4 结论

该实验清楚展示了 Lasso 的核心权衡：较小的 λ 利于拟合精度，较大的 λ 利于稀疏恢复。正式主实验最终采用 $\lambda = 0.2$ ，是出于“更适合展示稀疏结构”的考虑。

10 实验四： ρ 敏感性分析

10.1 实验目的

研究 ADMM 参数 ρ 对收敛速度和最终结果的影响。

10.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho \in \{0.1, 0.5, 1, 5, 10\}$

10.3 主要结果

ρ	ADMM iter	说明
0.1	726	收敛很慢
0.5	149	明显改善
1	80	最快
5	185	再次变慢
10	376	明显变慢

10.4 结论

不同 ρ 对最终恢复误差影响不大，但对收敛速度影响显著。当前实验设置下， $\rho = 1$ 最合适。

11 实验五：噪声强度实验

11.1 实验目的

考察观测噪声水平对稀疏恢复难度的影响。

11.2 实验设置

- $m = 150$
- $n = 500$
- $s = 20$
- $\lambda = 0.2$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10\}$

11.3 主要结果

以 ADMM 为例：

σ	recovery_error	nnz
0.00	1.058223	17
0.01	1.056204	19
0.05	1.067471	26
0.10	1.301248	50

11.4 结论

噪声越大，恢复误差越大，恢复出的解越不稀疏，说明噪声会显著破坏对真实稀疏结构的识别能力。

12 实验六：多随机种子重复实验

12.1 实验目的

前面的主实验大多基于单个随机种子。为了减少单次随机生成数据带来的偶然性，我们进一步在多个随机种子下重复主实验，并统计各指标的均值与标准差。

12.2 实验设置

- 主实验参数保持不变：
 - $m = 150$
 - $n = 500$
 - 稀疏度 $s = 20$

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$
- 随机种子取 $\{0, 1, 2, 3, 4\}$
- 记录指标：
 - 恢复误差均值与标准差
 - 非零元素个数均值与标准差
 - 迭代次数均值与标准差

12.3 实验结果

算法	recovery_error_mean	nnz_mean	iter_mean
ADMM	0.934555	21.4	81.8
FISTA	0.934569	21.4	215.0
ISTA	0.934565	21.4	229.6
Subgradient	1.120904	499.2	800.0

12.4 结果分析

1. ADMM、ISTA、FISTA 在恢复误差和稀疏度上都较为稳定，说明主实验结论不是偶然现象；
2. ADMM 的平均迭代次数显著低于 ISTA 和 FISTA；
3. Subgradient 即使在重复实验下仍然表现最差，说明其劣势是稳定存在的，而不是某一次随机实验造成的。

12.5 结论

重复实验显著增强了结果的可信度，也使本项目从“单次演示实验”提升为“具有统计稳定性分析”的期末作业。

13 实验七：三档规模对比实验

13.1 实验目的

研究问题规模增大时，各算法的恢复误差、稀疏性和收敛速度如何变化。相比只增大某一个参数，三档规模对比更能系统展示算法在高维场景下的适应性。

13.2 实验设置

固定：

- $\sigma = 0.05$
- $\lambda = 0.2$
- $\rho = 1$

三档规模分别为：

- 小规模： $m = 80, n = 200, s = 10$
- 中规模： $m = 150, n = 500, s = 20$
- 大规模： $m = 300, n = 1000, s = 30$

13.3 实验结果

规模	算法	recovery_error	nnz	iter
80/200/10	ADMM	0.578516	7	70
80/200/10	ISTA	0.578516	7	97
80/200/10	FISTA	0.578516	7	117
80/200/10	Subgradient	0.582503	200	800
150/500/20	ADMM	1.067471	26	80
150/500/20	ISTA	1.067482	26	241
150/500/20	FISTA	1.067467	26	254
150/500/20	Subgradient	1.248809	499	800
300/1000/30	ADMM	1.235796	31	84
300/1000/30	ISTA	1.235805	31	221
300/1000/30	FISTA	1.235818	31	198
300/1000/30	Subgradient	1.393068	1000	800

13.4 结果分析

1. 随着问题维度从 200 增长到 1000，ADMM、ISTA、FISTA 的恢复误差有所上升，这是更高维问题更困难的自然表现；
2. 在三档规模下，ADMM 与 ISTA/FISTA 的恢复误差几乎一致，说明它并未牺牲解质量；
3. ADMM 在三档规模下的迭代次数始终较低，分别为 70、80、84，展现出较好的规模适应性；

4. Subgradient 在所有规模下都表现最差，且始终跑满最大迭代次数。

13.5 结论

三档规模实验表明，随着问题规模增大，ADMM 仍然能够在保证解质量的同时保持较低的迭代成本，这进一步支撑了其在高维稀疏恢复问题中的效率优势。

14 实验八：正则化路径可视化

14.1 实验目的

观察“所有特征系数随 λ 变化的路径”，直观展示 Lasso 如何通过增大正则化强度逐步压缩系数。

14.2 实验设置

- 合成数据
- 求解器：ADMM
- $\lambda \in \{0.01, 0.02, 0.05, 0.1, 0.2, 0.5, 1.0\}$

14.3 结果解释

随着 λ 增大，越来越多的特征系数逐渐向 0 收缩，路径图可以清楚展示 Lasso 的稀疏机制。这项实验已经满足最初方案中的“正则化路径可视化”设想。

15 实验九：相变分析

15.1 初版问题

最开始，相变分析采用更高维、更严格设置，得到的成功率全部为 0，无法形成有效曲线。

15.2 改进后的正式设置

为得到更有解释性的相变趋势，我们采用：

- $m = 120$
- $n = 300$
- 稀疏度 $s = 10$

- $\lambda = 0.1$
- $\rho = 1$
- $\sigma \in \{0.00, 0.01, 0.05, 0.10, 0.20\}$
- 每个噪声水平重复 10 次

15.3 两种成功标准

1. **严格标准 (exact)**: 恢复出的支撑集与真实支撑集完全一致才算成功;
2. **宽松标准 (relaxed)**: 命中至少 80% 的真实非零位置即视为成功。

15.4 严格版结果

- $\sigma = 0.00$ 时成功率约 0.3
- $\sigma = 0.01$ 时成功率约 0.5
- $\sigma \geq 0.05$ 时成功率降为 0

15.5 宽松版结果

- $\sigma = 0.00, 0.01, 0.05, 0.10$ 时成功率接近 1.0
- $\sigma = 0.20$ 时成功率约 0.9

15.6 结论

严格标准下, 仅低噪声时才有较明显的完全恢复概率; 宽松标准下, 算法在低到中等噪声下仍能恢复大部分真实非零位置。该实验现已能够支撑“相变分析”的汇报内容, 同时也反映出我们对初版不理想实验结果所做的修正。

16 实验十：真实数据实验

16.1 真实数据一：diabetes

16.1.1 实验目的

验证算法在小规模真实回归任务中的预测误差和收敛效率。

16.1.2 结果特点

- 四种算法的预测误差接近；
- ADMM 收敛较快；
- 修正步长后，Subgradient 可以稳定运行。

16.2 真实数据二：wine_red

16.2.1 实验目的

作为第二个真实回归数据集，验证结果是否在另一个数据集上仍然成立。

16.2.2 实验设置

使用 UCI Wine Quality 红酒数据集，目标变量为 `quality`，其余数值列作为特征。

16.2.3 结果特点

- $\lambda = 0.05$ 与 $\lambda = 0.2$ 的结果差异很小；
- 四种算法预测误差非常接近；
- ADMM 的迭代次数最少，效率优势清晰；
- Subgradient 虽然能运行，但整体效率不如其他方法。

16.3 真实数据三：Communities and Crime

16.3.1 实验目的

将实验扩展到一个更复杂的高维真实回归数据集，用于验证 Lasso 及其优化算法在“存在缺失值、需要清洗、特征维度较高”的实际场景中的表现。

16.3.2 数据特点

- 原始数据包含 1994 个样本、128 个属性；
- 存在缺失值；
- 包含若干 ID/名称类非预测字段；
- 目标变量为 `ViolentCrimesPerPop`。

16.3.3 清洗流程

为保证可用于回归实验，我们采用了以下清洗流程：

1. 使用 `communities.names` 恢复列名；
2. 将 `?` 视为缺失值；
3. 删除非预测列：`state`, `county`, `community`, `communityname`, `fold`；
4. 删除缺失比例超过 30% 的特征列；
5. 对剩余缺失值使用中位数填补；
6. 划分训练集/测试集，并进行标准化。

清洗后最终保留了 100 个有效特征。

16.3.4 实验结果与分析

我们分别测试了 $\lambda = 0.05, 0.2, 1.0$ 。结果表明：

- 在 $\lambda = 0.05$ 和 $\lambda = 0.2$ 下，模型几乎保留了全部特征，稀疏化效果不明显；
- 当 $\lambda = 1.0$ 时，FISTA 与 ADMM 的非零特征数明显下降到 84 和 83，开始体现较强的稀疏化作用；
- 同时测试误差没有明显恶化，说明在该复杂真实数据上，更强正则化可以在不显著损失泛化性能的情况下提升稀疏性。

16.3.5 结论

Communities and Crime 数据集的价值不在于其特征维度一定高于合成数据，而在于它是真实的、带缺失值的、清洗成本较高的复杂回归数据集。它补充说明了：Lasso 的特征选择作用在复杂真实数据上同样存在，但往往需要更强的正则化参数才能显现。

17 当前总体结论

综合目前已经完成的实验，可以得到以下核心结论：

1. Subgradient 作为 baseline，整体收敛慢、稀疏性差，在合成数据上的表现明显弱于其他三种方法；
2. ISTA、FISTA、ADMM 都可以有效求解 Lasso，其中 ADMM 在当前实验中迭代次数通常最少；
3. λ 控制拟合误差与稀疏性的平衡；

4. ρ 主要影响 ADMM 的收敛速度，而不是最终解；
5. 噪声越大，稀疏恢复越困难；
6. 多随机种子重复实验表明主结论具有稳定性，不是单次随机实验的偶然结果；
7. 三档规模实验表明 ADMM 在问题规模增大时仍保持较好的效率优势；
8. 在真实数据上，结构化方法的预测精度通常接近，但 ADMM 仍具有较强的收敛效率优势；
9. 在更复杂的 Communities and Crime 数据集上，Lasso 的稀疏化作用需要更强的正则化参数才能明显显现；
10. 正则化路径和相变分析补足了本项目作为 Lasso 优化实验的完整性。

18 目前是否足以支撑期末大作业

从实验层次和内容覆盖度看，目前已经足以支撑一份期末小组大作业。原因是：

- 有理论模型；
- 有四种算法；
- 有不同规模的合成数据；
- 有参数分析；
- 有噪声分析；
- 有重复实验稳定性分析；
- 有问题规模扩展分析；
- 有正则化路径；
- 有相变分析；
- 有三个真实数据集验证。

因此，后续工作的重点不应再是盲目扩展实验数量，而应转为：

1. 整理图表；
2. 完善实验分析文字；
3. 组织 PPT 展示逻辑；
4. 统一报告的最终叙述口径。

19 后续还需要补什么

目前更需要补的是整理工作，而非额外跑大量新实验。建议后续分工如下：

19.1 需要整理的表格

- 四算法主实验对比表
- λ 敏感性结果表
- ρ 敏感性结果表
- 噪声实验结果表
- 真实数据实验结果汇总表 (diabetes、wine_red、Communities and Crime)

19.2 建议放入正式报告/PPT 的图

- 合成数据收敛曲线图
- 合成数据稀疏恢复图
- 正则化路径图
- 相变分析图（严格版和宽松版至少选一张）
- 一张真实数据结果汇总表

19.3 建议在 PPT 中讲清楚的重点

1. 为什么要研究 Lasso；
2. 为什么要比较这四种算法；
3. 为什么 ADMM 适合该问题；
4. 为什么最终主实验参数选为 $\lambda = 0.2, \rho = 1$ ；
5. 为什么相变分析需要从初版结果进一步修正；
6. 最终三到四条最核心的结论是什么。

20 建议的最终报告结构

1. 研究背景与问题定义
2. Lasso 模型与算法介绍
3. 实验设置
4. 合成数据主实验
5. 参数敏感性分析
6. 噪声实验与相变分析
7. 正则化路径分析
8. 真实数据实验
9. 实验中遇到的问题与修正
10. 总结与展望

21 给组员的一句话总结

目前实验主体已经完成，且已经从初版不理想结果中修正出一套正式版实验。接下来最重要的工作不是再无控制地扩实验，而是把现有结果整理成清晰的图表、结论和 PPT 叙述。